

EVALUACIÓN DINÁMICA DE UNA ARQUITECTURA MULTI-AGENTE BAJO LÓGICA DIFUSA

Adrian Fernando Acarapi Roca Grace Abigail Luna Verdueta Alvaro Daniel Callata Suxo
Universidad Católica Boliviana “San Pablo” – La Paz, Bolivia

El paradigma de sistemas multi-agente (MAS) basados en LLMs (AutoGen, CrewAI, LangGraph, AWS Strands) enfrenta tres problemas combinados: (1) agentes concurrentes sin reloj global generan propuestas conflictivas; (2) los modelos cloud ofrecen razonamiento superior a un costo por token, mientras los modelos locales son gratuitos pero limitados; (3) los algoritmos de consenso clásicos (Paxos, Raft, BFT) operan sobre valores discretos y no pueden evaluar la calidad semántica de una respuesta en lenguaje natural.

Objetivo: modelar matemáticamente, mediante lógica difusa tipo Mamdani, la comunicación entre agentes para lograr una segregación óptima de responsabilidades entre infraestructura *on-premise* y modelos en la nube, evaluando la eficacia de un cambio dinámico de responsabilidades.

- Motor de Inferencia Difusa (FIE) con 3 variables de entrada y base de **27 reglas**, evaluado en < 1.2 ms por propuesta.

- Métrica de incertidumbre operacional basada en entropía de Shannon normalizada sobre log-probabilidades por token, a costo marginal cero.

- Algoritmo de consenso asíncrono que resuelve conflictos vía similitud de embeddings y soporte ponderado difuso.

- Mecanismo de *routing* adaptativo local/nube con contabilidad de costo por token, validado en un benchmark de 150 tareas.

Tres tipos de agentes autónomos se comunican sobre un canal de broadcast asíncrono (**ThreadPoolExecutor**):

Engineering Agent (EA) — Llama 3.2 (3B, local vía Ollama). Tareas de bajo nivel: inspección de código, logs, SQL.

Support Agent (SA) — Gemma 3 (12B). Interpretación semántica de alto nivel y flujo procedimental.

Metric Auditor (MA) — monitor pasivo que mantiene la confiabilidad histórica FH vía media móvil exponencial:

$$FH_{t+1} = \alpha \cdot 100 \cdot \mathbb{I}[\text{éxito}] + (1 - \alpha)FH_t, \quad \alpha = 0.15$$

Fuzzy Orchestrator Core (FOC) — entidad central: recibe tareas, difunde a los agentes (ventana $\tau = 10$ s), invoca el FIE, aplica fusión por consenso y ejecuta el *routing*. No genera respuestas propias.

El soporte de consenso difuso pondera la similitud mutua (Jaccard o coseno de embeddings **nomic-embed-text**) por la confianza de los pares:

$$SP_i = \sum_{j \neq i} s_{ij} \cdot NC_j^*, \quad W_i = \frac{NC_i^*(1 + SP_i)}{\sum_k NC_k^*(1 + SP_k)}$$


Las propuestas con $W_i > \theta = 0.30$ se fusionan; si $\max(W_i) < \gamma = 0.25$ se declara desacuerdo irresoluble y se escala a la nube.

Funciones de membresía triangulares/trapezoidales ($O(1)$) sobre tres variables de entrada:

- Complejidad Semántica** $CS \in [0, 100]$: combinación lineal de densidad de palabras clave, profundidad gramatical y longitud de contexto — calculada analíticamente, sin llamadas a LLM.

- Incertidumbre de Respuesta** $IR \in [0, 1]$: entropía de Shannon normalizada sobre las $k = 5$ alternativas de log-probabilidad por token.


- Confiabilidad Histórica** $FH \in [0, 100]$: tasa de éxito acumulada del agente.




Funciones de membresía de las tres entradas (CS , IR , FH) y las dos salidas (NC , IEN).

Implicación de Mamdani sobre las $3^3 = 27$ combinaciones; agregación por máximo y defuzzificación por centroide ($N = 101$ puntos):

$$w^* \approx \frac{\sum_{i=1}^N w_i \cdot \mu_{C^*}(w_i)}{\sum_{i=1}^N \mu_{C^*}(w_i)}$$




Evaluación completa del FIE ($CS=70$, $IR=0.6$, $FH=40$): fuzzificación, agregación tipo Mamdani y defuzzificación por centroide $\rightarrow$ **ESCALATE** en 0.59 ms.



Tres compuertas numéricas explícitas (τ , $IEN_{thr}^* = 25$, $\gamma = 0.25$) pueden desviar una tarea a la nube; el resto se fusiona y resuelve localmente.

Benchmark sintético de 150 tareas (semilla fija 42, 3 estratos de complejidad). Juez: Amazon Nova Lite (protocolo LLM-as-judge).

Métrica	Local	Cloud	Híbrido
Latencia media (s)	44.71	3.28	32.60
Costo / 1k tareas (USD)	\$0.00	\$1.44	\$0.39
Precisión global (%)	74.7	100.0	81.3
Tasa de escalada (%)	0.0	100.0	27.3
Falsos positivos (%)	—	—	2.0
Detección alta complej. (%)	—	—	74.0



Reducción de costo del 72.9% respecto a Pure-Cloud (\$1.44→\$0.39), recuperando gran parte de la brecha de precisión frente al techo de nube (100%). La configuración Fuzzy-Hybrid no está dominada por ningún baseline en el plano costo-precisión.

- La latencia media del híbrido (32.6s) supera a Pure-Cloud (3.28s): el cuello de botella es la inferencia de Gemma 3 12B con *offloading* parcial a CPU, no la red. La ventaja es económica, no temporal.
- La entropía de Shannon promediada por token es un estimador imperfecto de IR : los tokens funcionales de baja entropía diluyen la señal de los tokens de contenido ($IR \approx 0.30$ en los tres estratos), por lo que IEN termina gobernado casi exclusivamente por CS .
- Trabajo futuro: entropía selectiva por posición de contenido, sistemas difusos Tipo-2, optimización de parámetros por gradiente y validación en incidentes industriales reales.

El FIE reemplaza el patrón de LLM-manager por un evaluador determinista $O(N)$ de < 1.2 ms, logrando **72.9% menos costo** y **81.3% de precisión**, sin llamadas adicionales a LLM para el enrutamiento.