

Evaluación de la Comprensión Semántica en la Traducción de LSA-T

Ignacio Giuliano Iannello iannello@dc.uba.ar

Departamento de Computación / Facultad de Ciencias Exactas y Naturales / Universidad de Buenos Aires

1. Introducción


El Lenguaje de Señas Argentino (LSA) tiene características que lo diferencian de otros lenguajes de señas como el ASL (American Sign Language) o el CSL (Chinese Sign Language). Existen diferencias tanto en el significado de gestos como en su estructura gramatical. Por ejemplo, LSA utiliza Objeto-Sujeto-Verbo mientras que ASL usa Sujeto-Verbo-Objeto.

Los avances recientes en la traducción y comprensión de lengua de señas han estado marcados por la aparición de nuevos conjuntos de datos y entornos de trabajo. Dal Bianco et al. [1] presentan LSA-T, el primer conjunto de datos continuo diseñado específicamente para la traducción de señas sin necesidad de glosas. Por su parte, Hwang et al. [2] proponen SpaMo, un framework que extrae características espaciales y de movimiento mediante codificadores visuales y las integra en un modelo de lenguaje de gran tamaño (LLM). Finalmente, Testa et al. [3] desarrollaron un pipeline automático para evaluar sistemas de comprensión de lengua de señas, aplicándolo a los datasets PHOENIX y CSL-Daily.

El objetivo de este poster consta en reproducir el pipeline de Testa para evaluar el modelo entrenado en LSA-T centrandose en la precisión de la comprensión semántica (SLU, Sign Language Understanding)

3. Detalles Técnicos

El modelo replica la arquitectura SpaMo [2]: utilizando las features espaciales (CLIP) y de movimiento (VideoMAE) se proyectan linealmente a 768 dimensiones, se suman y se procesan con dos bloques Conv1D+MaxPool para capturar dependencias temporales. Un MLP de dos capas con GELU produce los embeddings finales que se inyectan en el LLM.



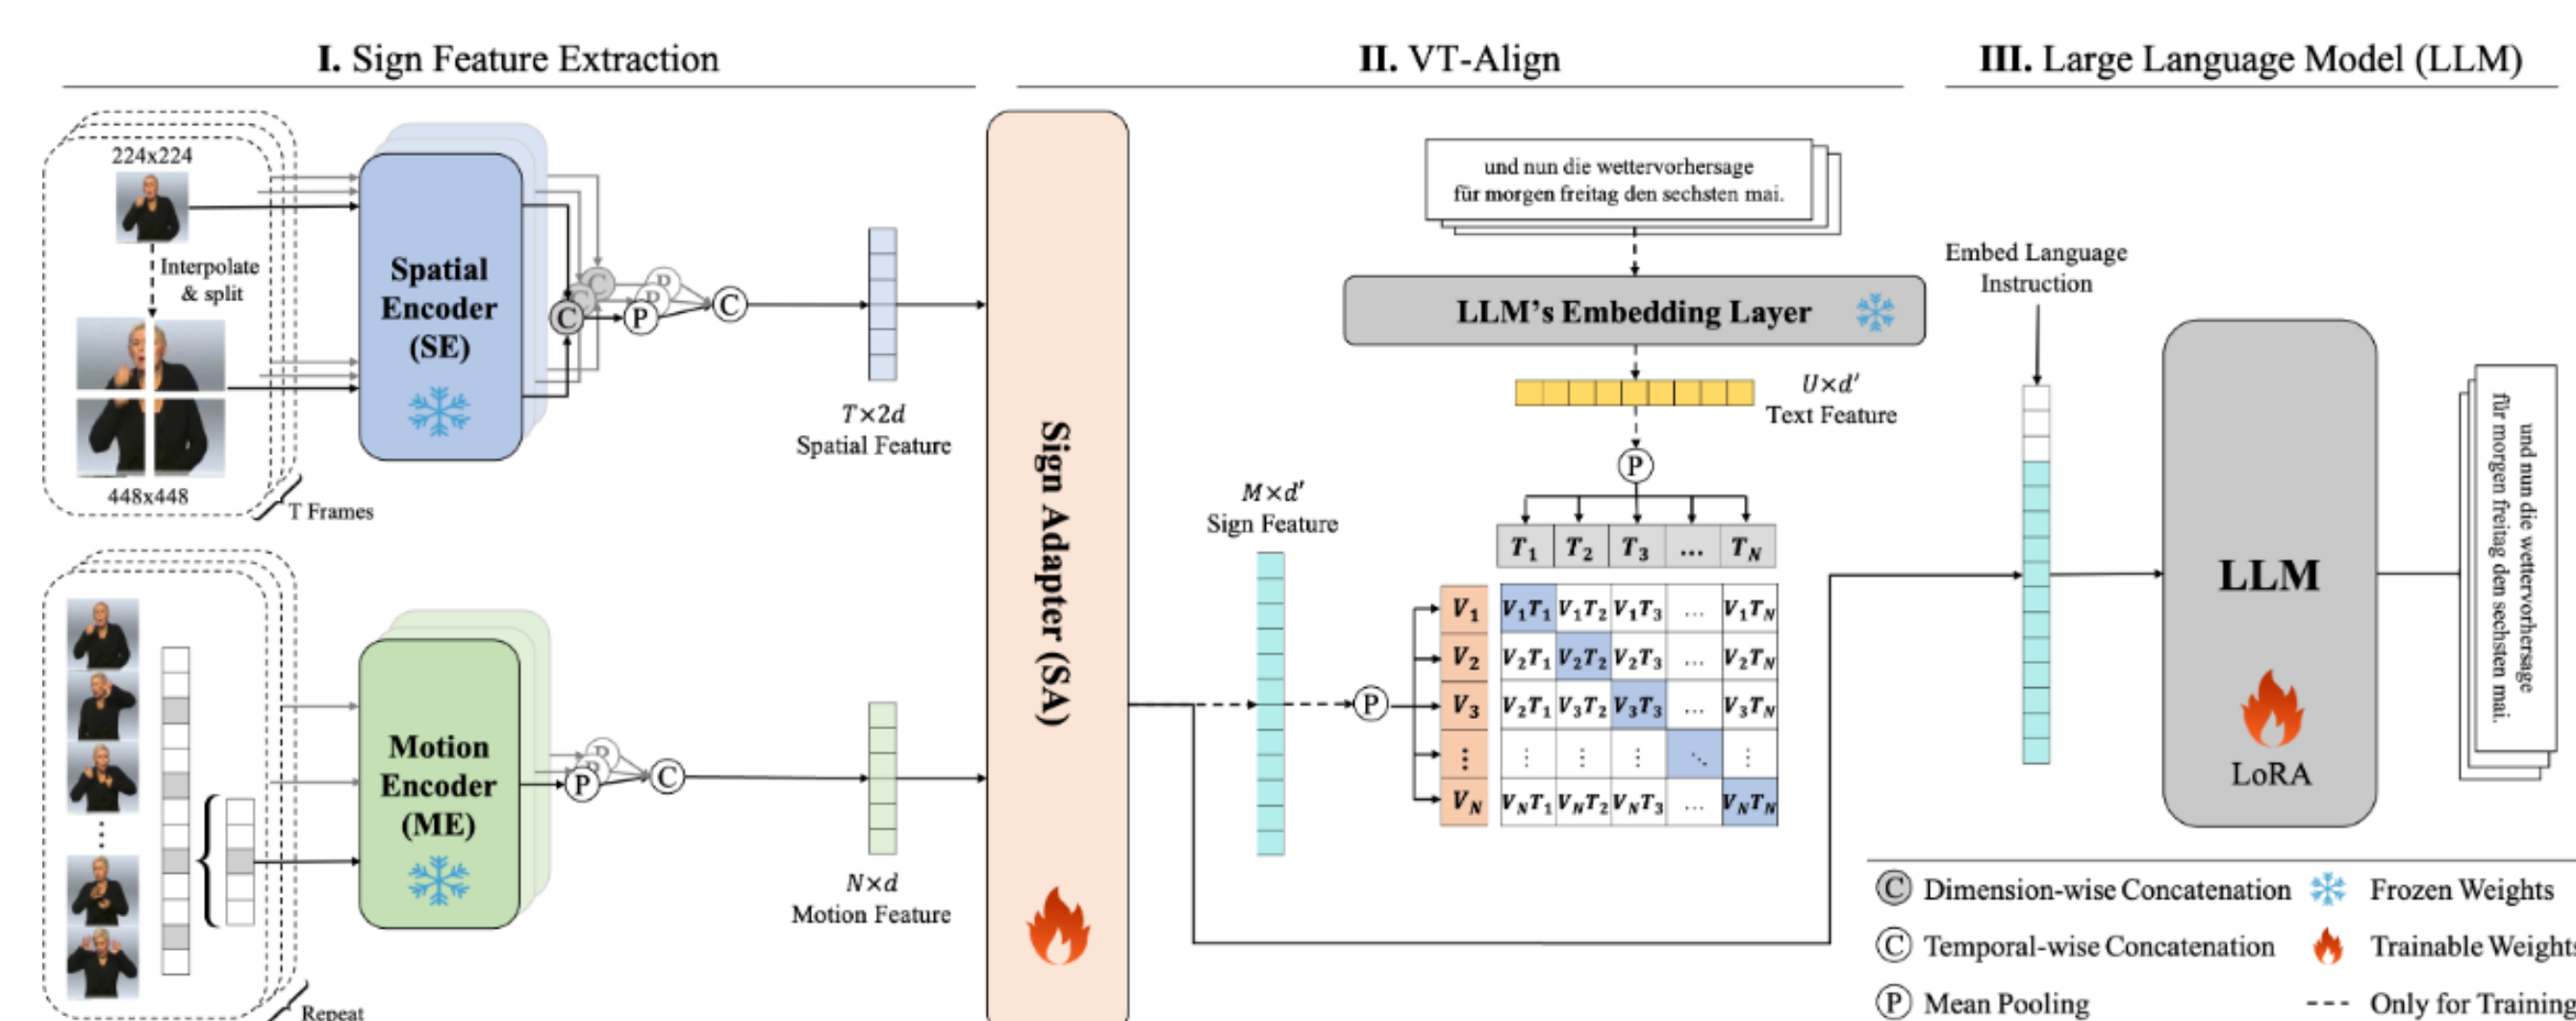
Estructura del módulo Sign Adapter. Su objetivo es combinar las features del Motion Encoder y el Spatial Encoder para proyectarlas linealmente al espacio de representación del LLM [2].

Entrenamiento:

- LLM: Flan-T5-Base utilizando LoRA en capas q y v ($r = 16$, $\alpha = 32$, dropout=0.05).
- Parámetros entrenables: 1.77M (0.59% del total).
- Optimizador: AdamW ($lr = 1e-4$, weight decay=0.01) con scheduler warmup+coseno.
- 50 épocas, batch size 16, pérdida: CrossEntropy con label smoothing (0.1).

2. Metodología

- **Datos:** Dataset LSA-T [1] con características espaciales (CLIP) y de movimiento (VideoMAE) preextraídas.
- **Modelo:** Adaptador SpaMo [1] + Flan-T5-Base con LoRA.
- **Pipeline de evaluación:** Adaptación del pipeline de Testa et al. [3] para generación de preguntas SLU.
- **Implementación:** Adaptador SpaMo + LoRA sobre Flan-T5-base; entrenado con scheduler personalizado y label smoothing.
- **Métricas:** BLEU-1, BLEU-2, BLEU-3, BLEU-4.



Estructura original del modelo SpaMo [2].




Diagrama de flujo de la generación de preguntas de SLU-2K [3].

4. Resultados Preliminares

Modelo	BLEU-1	BLEU-2	BLEU-3	BLEU-4
Nuestro modelo	11.37%	3.00%	1.02%	0.38%
Dal Bianco et al. (baseline)	6.4%	5.0%	0.38%	0.2%

Tabla 1: Métricas BLEU comparativas.

Ejemplos representativos:

- Buena traducción: “también esta la ley, que es muy importante.” → “es muy importante.” (BLEU-4: 22.31%)
- Mala traducción: “chau. chau.” → “hola, ¿cómo están?” (BLEU-4: 0.00%)

5. Conclusiones y Trabajo Futuro

Conclusiones:

- Nuestro modelo obtiene una mejora en BLEU-1, BLEU-3, BLEU-4 respecto al baseline
- La calidad de la traducción automática actual no es suficiente para aplicar el pipeline automatizado de SLU-2K, lo que sugiere que se necesita mejorar el modelo base, a pesar de tener las preguntas ya generadas

Trabajo Futuro:

- Mejorar la extracción de características (por ejemplo, usando modelos más potentes o combinando múltiples encoders).
- Generar características de manos, cuerpo y labios, alineándose con la literatura estándar en Sign Language Translation.
- Explorar estrategias de aumento de datos y ajuste fino con más épocas o diferentes arquitecturas.

References

- [1] Pedro Dal Bianco et al. *LSA-T: The first continuous Argentinian Sign Language dataset for Sign Language Translation*. 2022. arXiv: 2211.15481 [cs.CV]. URL: <https://arxiv.org/abs/2211.15481>.
- [2] Eui Jun Hwang et al. *An Efficient Sign Language Translation Using Spatial Configuration and Motion Dynamics with LLMs*. 2025. arXiv: 2408.10593 [cs.CL]. URL: <https://arxiv.org/abs/2408.10593>.
- [3] Zeno Testa et al. *SLU-2K: A Question-Based Benchmark for Semantic Evaluation of Sign Language Translation*. 2026. arXiv: 2606.03788 [cs.CV]. URL: <https://arxiv.org/abs/2606.03788>.

AGRADECIMIENTOS

A la **Escuela Sudamericana de NLP** por la beca de impresión.
A mis tutores y colegas por su apoyo en esta investigación.