

La evolución del razonamiento

Colapso de razonamiento en LLMs: enmascarando problemas para descifrar el razonamiento

Iván Agustín Bravo · Mariano Demarí · Aryo Lotfi · Samy Bengio · Manuel Der

ibravo@pluszero.app · mariano.demaria@pluszero.app · bengio@apple.com · manu.der@pluszero.app

Contexto y una pregunta guía


Si a un LLM le hacemos una pregunta que implica solo razonar, ¿responde con patrones similares a los de un humano, o tan solo recita soluciones que ya aprendió de memoria en algún momento de su entrenamiento? [1, 2] *The Illusion of Thinking* (Apple, 2025) [1] busca responder esta disyuntiva, la cual toma relevancia creciente conforme crece la promesa de que dichas arquitecturas puedan reemplazar a humanos expertos en tareas complejas, sin importar el campo de estudio en cuestión. En [1], Apple estudia LLMs y LRMs sobre problemas de complejidad controlable por un único parámetro de complejidad n . El caso más estudiado en nuestro trabajo son las Torres de Hanoi. Aquí, n es la cantidad de discos. Estos serán los «problemas» del presente trabajo. Fijado n , se efectúa la misma query B veces para calcular la *accuracy*, la proporción de respuestas correctas. [1] reporta que la accuracy de las respuestas colapsa rápidamente a 0 una vez que se supera cierto umbral de complejidad.

Nuestros aportes y hallazgos

- Definición de la *colapsidad*: una métrica para cuantificar el *desempeño característico* de un modelo al resolver cierto problema.
A partir de una curva de accuracies dependiente de la complejidad n , se obtiene la colapsidad n^* , un estadístico que cuantifica cuánto se puede aumentar n hasta que el modelo comience a contestar mal más de la mitad de las veces que se le consulta.
- Evaluación de la evolución de la colapsidad a lo largo de las generaciones sucesivas de un modelo.
Se observó cómo la colapsidad aumenta conforme progresan las generaciones, indicando mejora de desempeño de la mano de las mejoras tecnológicas.
- Desarrollo de técnicas para detección de overfitting en la resolución de problemas.
Introducimos los procesos de *enmascaramiento* y de *encriptación* sobre cierto enunciado. Estos son dos modos predeterminados para dar un enunciado que *nunca fue visto antes por el modelo*. Si bien –en términos lógicos– se plantea el *mismo problema*, solo se modifica la semántica. Estos clones fueron utilizados para computar sus colapsidades y sus vectorizaciones, a fin de tener una comparativa contra el enunciado clásico del problema.

Resultados clave

- La colapsidad de los enunciados originales del problema de las Torres de Hanoi es *máxima* respecto de sus 10 clones enmascarados. Esto se observa en 3 generaciones distintas del modelo open-source Qwen.
- Al obtener la vectorización según el modelo de los enunciados, proyectar sobre las primeras dos componentes principales muestra una discriminación llamativa del enunciado original respecto del resto de los datos: la primera componente lo distingue como cluster separado del resto.



Ejemplo de prompt (Hanoi original)


De [1] calcamos casi idénticos los system y user prompts para los dos problemas que estudiamos; a continuación, el system prompt del enunciado original de Hanoi. Notar que depende de n y pide explícitamente dar una respuesta en un formato predeterminado.

You are a helpful assistant. Solve this puzzle for me.
There are three pegs and n disks of different sizes stacked on the first peg. The disks are numbered from 1 (smallest) to n (largest). Disk moves in this puzzle must follow these rules:

- Only one disk can be moved at a time.
- Each move consists of taking the upper disk from one stack and placing it on top of another stack.
- A larger disk may not be placed on top of a smaller disk.

The goal is to move the entire stack to the third peg. Example: with 3 disks [...] the initial state is [[3, 2, 1], [], []] and a solution might be: moves = [[1,0,2], [2,0,1], [1,2,1], [3,0,2], ...]

Tres gráficos sintetizan todo



Ejemplo de prompt *enmascarado*

Notar cómo cambian pocas palabras clave, dejando inmutado el problema subyacente.

You are a helpful assistant. Solve this puzzle for me. In a busy restaurant kitchen, there are three serving stations and n plates of different diameters stacked on the first station. The plates are numbered from 1 (smallest) to n (largest). [...]

- Only one plate can be moved at a time.
- Each move consists of taking the top plate from one station and placing it on top of another station's stack.
- A larger plate may not be placed on top of a smaller plate (it would be unstable and slide off).

The goal is to move the entire stack of plates to the third serving station. [...] moves = [[1, 0, 2], [2, 0, 1], [1, 2, 1], [3, 0, 2], ...]

Conclusiones y trabajo venidero

Conclusiones

- En los modelos Qwen, la colapsidad mejora conforme las generaciones avanzan.
- En los modelos más avanzados Qwen aquí tratados, se encuentra una mejora de rendimiento sobre un enunciado de Hanoi clásico versus contrapartes iguales en cuanto a a su *lógica*, pero novedosas para el modelo.
- El modelo embebe discriminatoriamente al enunciado original de Hanoi respecto de sus contrapartes enmascaradas.

Trabajo venidero

- Hemos empezado a evaluar modelos de frontera (Claude, Gemini, etc.). También se sigue observando colapso en problemas del estilo de Hanoi.
- PlusZero está colaborando actualmente con Apple para enviar un trabajo al ICLR de este año; se está trabajando en una generación automática de variantes masked, mejor replicación y corroboración de resultados en modelos de frontera, entre otros.

Referencias

- [1] Parshin Shojaee et al. *The Illusion of Thinking: Understanding the Strengths and Limitations of Reasoning Models via the Lens of Problem Complexity*. Apple Machine Learning Research. Preprint. 2025.
- [2] Zhaofeng Wu et al. *Reasoning or Reciting? Exploring the Capabilities and Limitations of Language Models Through Counterfactual Tasks*. arXiv:2307.02477. 2024. URL: <https://arxiv.org/abs/2307.02477>.