


Métricas de evaluación para traducción automática qom ↔ español

Baselines, limitaciones y una hoja de ruta

Macarena Fernandez Urquiza | m.fernandezurquiza@gmail.com

Maestría en Exploración de Datos y Descubrimiento del Conocimiento — FCEN, UBA

Supervisoras: Viviana Cotik y Paola Cúneo



ICC Instituto de Ciencias de la Computación

Lacuna Fund Our voice on data

iLing UBA



DEPARTAMENTO DE COMPUTACIÓN Facultad de Ciencias Exactas y Naturales - UBA



1. Motivación

- Comunidad **qom** (toba); ~80.000 personas; 50 % habla o entiende la lengua.
- Región del **Gran Chaco** (norte argentino), migración a grandes ciudades.
- Lengua con uso en **retracción** y **escasos recursos digitales**.
- Traducción automática qom ↔ español como recurso valioso para **documentar y revitalizar** la lengua.
- Confiar en un traductor requiere **evaluarlo**: ¿cómo sabemos si sus traducciones son **adecuadas**?

2. Contexto



Fuente	# segm.	QomL-Bib.	QomL-Base	Base+Bib.
Biblia	30.449	✓		✓
Arte Verbal Qom	1.831		✓	✓
Educación Sanitaria Intercult.	212		✓	✓
Taller de Lengua y Cultura	273		✓	✓
Las aventuras de Copaic	16		✓	✓
El Principito	550		✓	✓
Declaración Univ. DD.HH.	61		✓	✓
Total (# segmentos)^c	30.449		2.882	33.331

^a distilled-600M | ^b QomL 'aqtaqa | ^c Se excluye la Declaración Univ. de los DD. HH. por no ser utilizada en el desarrollo de los modelos. | ^d Los modelos que incluyen más de una fuente cuentan con versiones entrenadas de forma estratificada y aleatoria.

Modelo desarrollado^d qom-mt-bible qom-mt-v1 qom-mt-v2

3. El problema

- ¿Cómo dar cuenta de la calidad de las traducciones automáticas? **Métricas de evaluación.**
- ¿Cuál es el desafío? Métricas existentes **poco robustas** o con limitaciones en lenguas de bajos recursos.

Métrica	Descripción	Limitación
Basadas en solapamiento de n-gramas entre texto esperado y predicho		
BLEU ³	Uso de n-gramas de palabras.	Penalización de variación léxica y morfológica.
ChrF++ ^{a4}	Uso de n-gramas de caracteres (y palabras).	Mayor robustez para morfología rica; penalización de la variación ortográfica.
Basadas en embeddings para representar texto esperado y predicho		
BERTScore ⁵	Representación vectorial y cálculo de similitud entre ambos textos.	Necesidad de un modelo pre-entrenado con gran cantidad de datos, difícil de obtener en contexto de bajos recursos.
MoverScore ⁶		
COMET ⁷	métrica presenta variaciones propias.	

^a Estándar reportado actualmente en competencias de NLP de lenguas de bajos recursos.

AmericasNLP 2025⁸: correlación **baseline** con juicios humanos ChrF++ $r \sim 0.6$, $\rho \sim 0.52$

4. Propuesta

Proponemos:

- Desarrollar **métricas de evaluación**:
 - **anotaciones humanas**
 - **técnicas automáticas**
- **Correlacionar** ambos tipos de métricas y **analizar** esa correlación.

Aspecto relevante: particularidades lingüísticas → impacto en tipos de error

- tipología de la lengua
- riqueza morfológica
- nivel de estandarización ortográfica

Referencias

¹ NLLB Team 2022 ² Cotik et al. 2026 ³ Papineni et al. 2002 ⁴ Popović 2017 ⁵ Zhang et al. 2019 ⁶ Zhao et al. 2019 ⁷ Rei et al. 2020 ⁸ de Gibert et al. 2025 ⁹ Lommel et al. 2013 ¹⁰ Feng et al. 2022 ¹¹ Lo 2019 ¹² Krasner et al. 2025 ¹³ Raja & Vats 2025



Bibliografía



Repositorio

5. Métricas a partir de evaluaciones humanas

- **Estatus:** elaboración del criterio de anotación en curso. | **Framework** candidato: **MQM**⁹.
- **Grupo de anotadores:**
 - homogéneo: reduce el riesgo de acuerdo bajo entre anotadores
 - con dominio robusto de ambas lenguas
 - perteneciente a la comunidad qom
 - con conocimiento técnico de la lengua
- **¿Mismos criterios en ambos sentidos?** Flexibilizar la ortografía en qom (sin estandarización plena); contemplar terminología cultural sin traducción unívoca.
- **Aspecto relevante:** factores socioculturales → impacto en soporte de anotación, formato.

Ejemplos (anotación inicial, 28 segmentos por dirección, tipo de error MQM más cercano entre paréntesis asignado **a posteriori** de la anotación):

qom → español

- Sustitución léxica + alucinación (MQMN_111100): “nido de guazuncho y cuero” en lugar de “gallineros y corrales”.
- Desajuste sintáctico / estructura de la información (MQMN_201030): “para los qom” traducido como “esa gente toba”.

español → qom

- Limitación morfosintáctica (MQMN_201020): orden de palabras inadecuado, p.ej. la posición de “ndoteec” (“solamente”) en “Ndoteec da aïem ‘auchoxoden” es semánticamente comprensible pero gramaticalmente incorrecta.


6. Métricas automáticas y primeros avances

En curso:

- **Basadas en n-gramas:**
 - evaluación de modelos con valores estándares y alternativos de parámetros
 - correlacionar con evaluaciones realizadas por humanos
- **Basadas en embeddings:**
 - qué datos (digitalización de nuevas fuentes)
 - qué particiones (estratificación, evitar el uso de Biblia en *test* y *data leakage*)
 - cuál es el rendimiento sin *fine-tuning*
 - qué modelo base; referencias → AmericasNLP 2025: **LaBSE**¹⁰ + [**YiSi-1**¹¹ o **COMET** o esquemas de **similitud/regresión**] (Krasner et al.¹²; Raja & Vats¹³).

Primeros avances:

Baselines sobre el test estratificado de qom-mt-v1 ($n = 386$):



Contaminación train/test: biblia no presenta; variantes aleatorias tienen ~70 % de solapamiento.


Significancia (ChrF++): test de permutación pareado ($N = 100$, $\alpha = 0.05$). Todas las diferencias entre modelos resultaron significativas, **excepto:** *biblia* vs. *v1-estrat.* (en qom2es y es2qom) y *v1-aleat.* vs. *v2-estrat.* (solo qom2es).

		exacto ambas	exacto 1 leng.	casi dup	total
qom-mt-v1	estrat.	0 %	1 %	5 %	6 %
qom-mt-v2	estrat.	5 %	1 %	6 %	12 %

1 leng.: solo un lado; **casi dup:** similitud TF-IDF ≥ 0.85 .

Correlación con juicio humano (anotación inicial, $n = 56$):

chrF++ por segmento vs juicio humano — color por split — modelo: qom-mt-v2-aleatorio



△ Segmentos de anotación previa y mayormente presentes en *train* (contaminación).