

Lengua qom: Creación de un corpus de habla y de texto paralelo, aplicaciones y evaluación

Christian Cossio-Mercado
ccossio@dc.uba.ar
ICC (CONICET-UBA)
DC, FCEN, UBA

Viviana Cotik
vcotik@dc.uba.ar
ICC (CONICET-UBA)
DC, FCEN, UBA

Paola Cúneo
pcuneo@gmail.com
CONICET / UBA
iLing, FFyL, UBA


Macarena Fernández Urquiza
m.fernandezurquiza@gmail.com
Maestría de Data Mining, FCEN, UBA

Aleksei Korablev
aleksei@uni.minerva.edu
Minerva University

Temis Tacconi
temis.tacconi@gmail.com
iLing, FFyL, UBA

Belu Ticona
ticona.belu@gmail.com
George Mason University

1. Motivación



Fuente: Messineo (2014), p. 19.

- En la Argentina, **cerca de 20 lenguas indígenas** se usan en la comunicación cotidiana, y la mayoría se encuentra en **riesgo de desaparecer**.
- Los recursos digitales para las lenguas indígenas habladas en nuestro país son **sumamente escasos**.
- Los **corpus digitales** pueden contribuir a:
 - la **visibilización** y el **fortalecimiento** de las lenguas minorizadas;
 - la **investigación lingüística**;
 - el **procesamiento del lenguaje natural** y del habla.

Qom (o toba)

≈80.000 personas (INDEC, 2024).
Región del Gran Chaco y asentamientos urbanos.
Familia lingüística guaycurú, que incluye pilagá, mocoví y caduveo.
≈50 % de la población qom habla la lengua qom (INDEC, 2024).

- La lengua posee **recursos computacionales limitados**.
- Ausencia de un corpus paralelo** qom-español para MT.
- La **variación ortográfica** y las **diferencias estructurales** entre qom y español representan un **desafío** para las tecnologías del lenguaje.

Una muestra de la lengua qom

“Nache ñape aïem
da’aqtaxaapeguem
na aloic so huaxaïxalachigui.
‘Entonces mi abuelo me contaba
la locura del zorro mítico.’”

Rasgos relevantes de la lengua:

- Tendencia a la polisíntesis y a la aglutinación, con una rica morfología derivativa.
- Orden de constituyentes SVO/VS, con diferencias sistemáticas respecto del español.
- Ortografía estandarizada recientemente; hay variación en las fuentes disponibles.
- Variación dialectal.

2. Objetivo

Construir **corpus de habla en qom** y de **texto paralelo qom-español** que sirvan como recursos para:

- la documentación **lingüística**;
- el desarrollo de **tecnologías** para el procesamiento del habla y del lenguaje natural;
- la **revitalización** lingüística.

3. Metodología

- Contacto y trabajo previo** con la comunidad hablante.
- Entrevistas** con los/as hablantes: Conversaciones y preguntas basadas en los intereses y las motivaciones particulares de cada hablante (p. ej., contar la historia del barrio, explicar la elaboración de artesanías o narrar su historia personal).
- Participación de colaboradores qom como **entrevistadores**.
- Registro en **audio de alta calidad** (PCM 96 kHz, 32 bits) con micrófonos de vincha y ambientales.
- Procesamiento iterativo** de las grabaciones:



- Trabajo colaborativo** con la comunidad.
- Acompañamiento antropológico** para identificar necesidades de la comunidad y posibles aportes del proyecto (*en curso*).



Este trabajo es posible gracias al conocimiento, el compromiso y la generosidad de las y los colaboradores qom:
†Ramón Yúriga, Felipe Cerón, Graciela Delfino, Ana Medrano, Roque López, Virgilio Leiva, Omar Camachi y Estela Acosta. ¡Gracias!

4. El corpus

Corpus de habla

≈ 5 h de audio	< 5 h de audio transcrito y traducido	37,5 % de la duración de hablantes mujeres	3 de 4 variedades
-------------------	---	--	----------------------

- edades:** 40-80 años.
- variedades dialectales:** *dapigeml'ek*, *no'olgaGanaq*, *takshek*.
- géneros discursivos:** historias de vida, relatos míticos, relatos de humor, chistes, canciones de cuna, consejos, rogativas.
- modalidades:** habla espontánea y lectura.

Corpus de texto (Cotik et al., 2026)

33.392 segmentos	1,47 M tokens qom	891 mil tokens español	7 fuentes	QomL'aqtaqa nombre corpus
---------------------	----------------------	---------------------------	--------------	------------------------------

Desafíos del proyecto

- Obtener **grabaciones de alta calidad**.
- Diseñar disparadores para obtener **habla espontánea**.
- Definir **criterios de transcripción** teniendo en cuenta la variación ortográfica y dialectal.
- Integrar **perspectivas lingüísticas, computacionales y comunitarias**.

5. Trabajos en curso

- Sistema de traducción automática (MT)** qom ↔ español, basado en
 - el corpus paralelo existente;
 - las transcripciones y traducciones producidas a partir del nuevo corpus de habla.
- Estudio de **métricas de evaluación** para traducción automática.
- Implementación de un **sistema de reconocimiento automático del habla (ASR)**.
- Desarrollo de **materiales bilingües** de uso comunitario.
- Apoyo a **talleres de lengua qom** en contextos de desplazamiento lingüístico.

6. Conclusiones y trabajo futuro

- Se logró grabar un **corpus de habla de alta calidad** que abarca **tres variedades** del **qom** habladas en la Argentina.
- Se reforzó el **vínculo** establecido con la comunidad en investigaciones previas y se incorporaron **nuevas personas** al proyecto.
- Restan varias tareas por completar como parte del proyecto:
 - Finalizar la **transcripción y traducción** del corpus de habla.
 - Incorporar **nuevas grabaciones de mayor variedad**, obtenidas con celulares.
 - Publicar** los recursos y ponerlos a disposición de la comunidad.
 - Capacitar** a los/as hablantes en el registro y el estudio de su lengua.

7. Referencias

- Cotik, V., Korablev, A., Cúneo, P., & Laciana, P. (2026). **QomL'aqtaqa: A Qom-Spanish Parallel Corpus for Natural Language Processing with Machine Translation Evaluation**. In Proceedings of the Sixth Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP), pp. 186–202.
- Instituto Nacional de Estadística y Censos - INDEC (2024). **Censo Nacional de Población, Hogares y Viviendas 2022. Resultados definitivos. Población indígena o descendiente de pueblos indígenas u originarios**. CABA: INDEC.
- Messineo, C. (2014). **Arte verbal qom. Consejos, rogativas y relatos de El Espinillo (Chaco)**. Buenos Aires: Rumbo Sur.

