

# Representación dialectal en NLP: un benchmark para el español rioplatense y enriquecimiento de datos guiado por eye-tracking

Tadeo Kaufmann · Director: Bruno Bianchi · Codirector: Fermín Travi


## Una variedad ausente

El español rioplatense, hablado por 50 millones de personas en Argentina y Uruguay, está ausente de los principales benchmarks de evaluación de NLP. Los que existen usan una variedad más neutra, pero con rasgos y giros peninsulares.

- Esta tesis construye el primer benchmark de comprensión de texto en rioplatense.
- Y lo usa, además, para evaluar si la señal de **eye-tracking** mejora la comprensión de los modelos.


## Benchmark

Un benchmark es un conjunto de datasets que representa una tarea (por ejemplo, comprensión de texto) y permite comparar el rendimiento de distintos modelos entre sí.



## Eye-tracking

El eye-tracking es una técnica que registra los movimientos oculares de una persona mientras lee: qué palabras mira, cuánto tiempo se detiene en cada una, y en qué orden.



## Construcción de XNLIrp

XNLI es un dataset de inferencia textual, originado en inglés y traducido a numerosos idiomas, entre ellos español. Nos propusimos llevarlo al español rioplatense.


| PREMISA                         | HIPÓTESIS                 | IMPLICACIÓN |
|---------------------------------|---------------------------|-------------|
| "Sí, bueno, el chico está acá." | "El chico está presente." |             |

Los cambios fueron de varios tipos: léxicos, de formas verbales y adaptaciones culturales.


| TIPO | PENINSULAR    | RIOPLATENSE |
|------|---------------|-------------|
| B    | dinero        | plata       |
| B    | coche         | auto        |
| C    | tienes        | tenés       |
| C    | vosotros vais | ustedes van |
| E    | John          | Juan        |
| E    | Texas         | Córdoba     |

## Validación


La validación tuvo dos etapas: automática, con gpt-4o-mini (6.739 de 7.500 instancias aprobadas, 728 marcadas para corregir), y nativa, con una app web donde 339 hablantes rioplatenses calificaban del 1 al 5 qué tan natural sonaba cada oración y marcaban las palabras que no les sonaran así.



Pantalla de bienvenida.



Tarjeta de anotación.



Envío y ranking de anotadores.

|                     |                        |
|---------------------|------------------------|
| 7.500<br>INSTANCIAS | 339<br>ANOTADORES      |
| 3,73/5<br>PROMEDIO  | 84,2%<br>APROBADO (≥3) |

## QA-Dataset

Sobre los mismos cuentos leídos con eye-tracking, armamos una segunda tarea: QA-Cuentos ET.

|                                                                                                       |
|-------------------------------------------------------------------------------------------------------|
| <b>PREGUNTA</b><br>¿Cómo describían, uno por uno, a los integrantes del grupo de músicos?             |
| <b>ORACIÓN</b><br>"Eran tres: una pianista linda, un violinista gracioso y un flautista enloquecido." |
| <b>RESPONDE</b>                                                                                       |

|                           |                              |
|---------------------------|------------------------------|
| 1.788<br>PREGUNTAS        | 8.940<br>INSTANCIAS          |
| 20<br>CUENTOS CORTOS (ET) | 10<br>CUENTOS LARGOS (NO-ET) |

## Construcción de QA-Cuentos ET


A partir de Cuentos-ET se crea un segundo dataset de QA. Elegimos oraciones target por longitud, armamos un pool de distractoras del mismo cuento, y Gemini 2.5 Flash genera una pregunta que no se resuelva por simple solapamiento léxico.



Solo una oración responde de verdad.

## Experimentos: ¿la distancia dialectal perjudica a BETO?

Usamos BETO en los dos experimentos: el primero mide si evaluar en rioplatense perjudica su rendimiento en XNLIrp; el segundo, si el eye-tracking mejora su comprensión en QA-Cuentos ET.





BETO entrenado con las 390k instancias de XNLI-ES, evaluado en ES y RP, por tipo de cambio dialectal.

**Conclusión:** disponibilizamos dos datasets de comprensión de texto en rioplatense.

XNLIrp · QA-CUENTOS ET

## Validación de QA-Cuentos ET

Claude Haiku 4.5 valida cada instancia: recibe la pregunta y las 5 oraciones sin etiquetar y debe indicar cuáles responden la pregunta. Si no elige ninguna o elige más de una, la instancia se regenera.



F1 de BETO en QA-Cuentos ET por K: base, sin señal ET (control de dominio) y con señal ET.