

Transformers guiados por atención humana: integración de eye-tracking para mejorar el entrenamiento de modelos de lenguaje

Tomás Schmidt, Bruno Bianchi, Fermin Travi

tomas.schmidt2004@gmail.com, brunobian@gmail.com, fermintravi@gmail.com

1. Motivación

- Gran parte del progreso en inteligencia artificial se apoyó en el escalamiento de modelos de lenguaje con un costo de Hardware y energético muy alto que cada vez presenta mejoras más pequeñas.
 - Las señales cognitivas humanas y especialmente datos de movimientos oculares durante la lectura, **aparecen como una fuente de información especialmente valiosa** para mejorar la calidad de las señales recibidas por el modelo.
- Objetivo : **Integrar movimientos oculares humanos para mejorar el entrenamiento de modelos de lenguaje.**


2. Marco teórico

• Eye-tracking como señal humana

El eye-tracking es una técnica que permite registrar los movimientos oculares de una persona frente a un estímulo visual.

Hay 2 características principales:

- El **Scanpath** es el orden de lectura de la oración
- El **tiempo de fijación** es cuanto tiempo se quedó el lector viendo una Palabra.




Estas métricas parecen valiosas por la **hipótesis ojo-mente**

• Modelos de lenguaje: ideas necesarias


Transformers y atención

Modelos Transformer procesan el texto como una secuencia de tokens → A través del **mecanismo de atención, se capturan relaciones entre palabras cercanas y lejanas.**



RNN/GRU y orden secuencial

Redes recurrentes procesan información de manera ordenada, actualizando un estado interno en cada paso → El orden juega un rol clave



3. Papers Base


Paper base 1: rama auxiliar con scanpaths

Este trabajo incorpora señales de lectura humana durante el fine-tuning de un modelo de lenguaje preentrenado → Utiliza dos ramas de entrenamiento: una **rama estándar**, basada en el texto original y la tarea principal, y una **rama auxiliar guiada por scanpaths sintéticos**.

-En la rama auxiliar, las representaciones de los tokens se reordenan siguiendo el orden de fijaciones del scanpath y luego se procesan con una GRU.

-La pérdida se combina con la pérdida estándar → **Señal ocular actúa como guía adicional durante el entrenamiento.**

$$L = L_{\text{standard}} + \lambda L_{\text{scanpath}}$$



ET se aplica directamente durante el **Finetuneo del modelo** para una tarea específica

Paper base 2: máscaras de atención con eye-tracking


-Incorporar señales de eye-tracking directamente dentro del mecanismo de self-attention de un Transformer.

-El entrenamiento mantiene la estructura estándar, pero **modifica el cálculo de atención agregando una máscara construida a partir de señales humanas de lectura.**

$$scores_{ET} = \frac{QK^T}{\sqrt{d_k}} + M_{ET}$$

Atención estándar Máscara de atención

-Las métricas de lectura guían qué relaciones entre tokens reciben mayor atención → Métricas: **FFD** y **TRT**



4. Adaptaciones propuestas

Situación

Los trabajos originales usan BERT/Roberta en inglés.

Se dispone de datos reales de eye-tracking, medidos sobre textos en español.

El ET ya fue incorporado durante el reentrenamiento del modelo.

Problema

La tesis trabaja con textos y tareas en **español**.

No contamos con scanpaths sintéticos para incorporarlos directamente en el fine-tuning


¿Qué ocurre luego en el fine-tuning downstream?

Solución

Se reemplaza el modelo base por **BETO**

Se agrega una **etapa extra de reentrenamiento con ET** antes del fine-tuning.

El ET no se usa en esta etapa. El modelo reentrenado se ajusta con un fine-tuning breve, sin ET, sobre tareas específicas.



5. Resultados

Se han probado 2 configuraciones distintas de pruebas:

Fase Scanpath

Se agrega una rama auxiliar guiada por Scanpaths sintéticos

Fase Mascara

Se agrega una máscara de atención al mecanismo de atención del Transformer.

Intensidad por ubicación

Se fija la ubicación de la máscara y se varían las intensidades aplicadas.


Intensidad global

Distintas intensidades de máscara aplicadas a todas las capas.

Ubicación de máscaras


Se fija la intensidad y se prueban distintas configuraciones de ubicación de máscaras en las capas.

Resultados de Pre-Entrenamiento



Resultados del Fine-Tuning

Evaluación final downstream: media ± desvío estándar entre seeds



8. Conclusiones

- Las señales de **eye-tracking** **modificaron la dinámica de entrenamiento del modelo.**
- Las **mejoras** en tareas downstream fueron **pequeñas y no sistemáticas.**
- En Hate/Rioplatense aparecieron mejoras leves con mayor frecuencia.
- Los resultados sugieren que el **eye-tracking** en español **contiene una señal útil**, pero todavía limitada por la **cantidad de datos.**