

¿Cuán confiable es esta respuesta?

Medición de incertidumbre para
grandes modelos de lenguaje

Luciana Ferrer



Instituto de Ciencias
de la Computación

CONICET



El problema

- Los LLMs no nos dan información sobre su certeza
 - responden siempre con fluidez, incluso cuando se equivocan
 - rara vez declaran duda
- No están entrenados para ser honestos, sino para
 - replicar los patrones de los datos de entrenamiento (pre-training)
 - ser útiles (RLHF, instruction finetuning)

Ejemplo

Hace tres semanas que tengo tos seca, fatiga leve y fiebre baja ocasional. ¿Qué podría ser y qué debo hacer?



Una tos que dura tres semanas junto con fatiga y febrícula suele indicar una infección respiratoria persistente, como bronquitis aguda o un cuadro post-viral. También podría tratarse de influenza o un proceso similar.

¿Qué debes hacer?

Consulta a un médico: Dado que los síntomas ya llevan tres semanas y no han desaparecido, es fundamental que acudas a un profesional ...

No te automediques: Evita tomar antibióticos sin supervisión médica ...

Cuidados en casa: Mientras esperas tu cita médica ...

Ejemplo

Hace tres semanas que tengo tos seca, fatiga leve y fiebre baja ocasional. ¿Qué podría ser y **cuál es el tratamiento?**



Tus síntomas de tos seca, fatiga y fiebre baja persistentes por tres semanas suelen indicar una infección respiratoria viral prolongada, bronquitis o las secuelas de un cuadro previo ...

Tratamiento Orientativo

El manejo de estos síntomas se enfoca en aliviar el malestar mientras tu cuerpo se recupera ... Descanso e hidratación: ... Control de fiebre y dolor: ... Alivio de la tos: ...

Cuándo consultar a un médico

Busca evaluación profesional inmediata si experimentas:

Dificultad para respirar o falta de aire.

Dolor en el pecho al toser o respirar.

Fiebre alta o escalofríos intensos.

Expectoración con sangre.

Medidas de incertidumbre

- Alguna de las dos respuestas es incorrecta, pero ambas expresan certidumbre total!
 - Queríamos que el modelo nos diga que no está muy seguro
- Actualmente, esto se resuelve con un “parche”:
 - Dada una respuesta, se genera un puntaje de incertidumbre (o confianza)
 - Un valor numérico que se puede usar para rechazar una respuesta
 - En caso de respuestas compuestas, se genera un puntaje por sección

Tus síntomas de tos seca, fatiga y fiebre baja persistentes por tres semanas suelen indicar una infección respiratoria viral prolongada, bronquitis o las secuelas de un cuadro previo ... **90%**

Tratamiento Orientativo

El manejo de estos síntomas se enfoca en aliviar el malestar mientras tu cuerpo se recupera ... Descanso e hidratación: ... Control de fiebre y dolor: ... Alivio de la tos: ... **80%**

Cuándo consultar a un médico

Busca evaluación profesional inmediata si experimentas:
Dificultad para respirar o falta de aire.
Dolor en el pecho al toser o respirar.
Fiebre alta o escalofríos intensos.
Expectoración con sangre. **55%**

Agenda

- **Parte I — Métodos para cuantificar la incertidumbre**
- **Parte II — Evaluación de esas puntuaciones**



PARTE I

Métodos para cuantificar la incertidumbre

Nota sobre nomenclatura

- Confianza:
 - Probabilidad de que la salida del modelo sea correcta
- Incertidumbre:
 - Un concepto más general, que incluye
 - La entropía sobre las posibles respuestas
 - $1 - \text{la confianza}$
 - La incertidumbre óptima depende de cómo evalúo al modelo

Cuatro familias de métodos



Verbalización

Se pide al modelo que declare su propia confianza en palabras o números



Probabilidades

Valor derivado de las probabilidades de token calculadas por el modelo



Consistencia

Se muestrea varias veces y se mide cuánto coinciden las respuestas



Probing

Modelos entrenados, basados en las activaciones del modelo

Cuatro familias de métodos



Verbalización

Se pide al modelo que declare su propia confianza en palabras o números



Probabilidades

Valor derivado de las probabilidades de token calculadas por el modelo



Consistencia

Se muestrea varias veces y se mide cuánto coinciden las respuestas




Probing

Modelos entrenados, basados en las activaciones del modelo

Métodos que piden verbalizar la confianza

- Se promptea al modelo para que declare una confianza
 - Un número entre 0 y 100
 - Categorías cualitativas (baja / media / alta)
- Dos opciones:
 - Integrada: se pide en el prompt original
 - A posteriori: se usa un prompt aparte



Prompt:Cuál es el tratamiento para ...? Decime la respuesta y la probabilidad de que sea correcta.
Respuesta: Tomar jarabe para la tos (confianza: 90%)

Prompt1:Cuál es el tratamiento para ...?
Respuesta: Tomar jarabe para la tos
Prompt2: Para la pregunta “Cuál es el tratamiento ...” cuál es la probabilidad de que la respuesta “Tomar jarabe para la tos” sea correcta?
Respuesta: 90%

Métodos que piden verbalizar la confianza

- **Ventajas:**

- Se puede usar con cualquier modelo, incluso los black-box
- La opción integrada es barata, no requiere una nueva inferencia

- **Desventajas:**

- Alta sensibilidad al formato del prompt
- Baja precisión en la respuesta (números redondos o categorías)

Cuatro familias de métodos



Verbalización

Se pide al modelo que declare su propia confianza en palabras o números



Probabilidades

Valor derivado de las probabilidades de token calculadas por el modelo



Consistencia

Se muestrea varias veces y se mide cuánto coinciden las respuestas



Probing

Modelos entrenados, basados en las activaciones del modelo

Métodos basados en las probabilidades de los tokens

- Se calcula la **confianza** como la probabilidad de la secuencia de tokens generada

$$P(a|p) = \prod_i P(a_i | a_1 \dots a_{i-1} p)$$

Prompt, p
*Cuál es la
capital de
Francia*



Respuesta, a
La capital de Francia es Paris
 $a_1 a_2 \dots a_N$

- A veces se normaliza por la longitud (promedio geométrico)

Métodos basados en las probabilidades de los tokens

- **Ventaja:**

- Sin costo adicional

- **Desventajas:**

- No se puede hacer con modelos cerrados sin acceso a las probabilidades
- Puede no funcionar muy bien, por un par de razones ...

Problemas: Competencia de formas superficiales

- La probabilidad de la secuencia generada no es la confianza
 - Confianza: probabilidad de que la respuesta sea correcta
- Se reparte la masa de probabilidad entre paráfrasis del mismo significado



- Mismo significado, masa repartida en varias posibles secuencias
- Consecuencia: una respuesta correcta puede tener una probabilidad relativamente baja
- **Estrategia de mitigación:** reformular la respuesta, pasarlas por el LLM y sumar todas sus probabilidades

Problemas: Mala calidad de las probabilidades

- Los modelos base suelen generar buenas probabilidades de próximo token
- El RLHF y el ajuste por instrucciones tienden a resultar en modelos demasiado confiados
 - Sus probabilidades están exageradas hacia los extremos
 - Las probabilidades de las secuencias están sobre estimadas
- Aún si sumamos sobre variantes, van a seguir siendo malos puntajes de confianza
 - Aunque pueden ser útiles para ranquear respuestas

Hace tres semanas que tengo tos seca, fatiga leve y fiebre baja ocasional. ¿Qué podría ser y cuál es el tratamiento?



... Visitar al médico de manera urgente ... **99.9%**

... Visitar al médico si aparecen los siguientes síntomas ... **99%**

Cuatro familias de métodos



Verbalización

Se pide al modelo que declare su propia confianza en palabras o números



Probabilidades

Valor derivado de las probabilidades de token calculadas por el modelo



Consistencia

Se muestrea varias veces y se mide cuánto coinciden las respuestas



Probing

Modelos entrenados, basados en las activaciones del modelo

Métodos basados en la consistencia de las respuestas

- Se generan N respuestas con temperatura > 0 para el mismo prompt o variantes, para un modelo o varios
- Se agrupan por equivalencia semántica

Métodos basados en la consistencia de las respuestas

1 · Generar varias salidas

- París
- Es París
- La capital es París
- Es Lyon
- París, Francia
- La capital es Le Mans
- La ciudad de Paris
- La capital de Francia es Paris



2 · Agrupar equivalentes

● Grupo A — 6/8

París

● Grupo B — 1/8

Lyon

● Grupo C — 1/8

Le Mans



3 · Calcular incertidumbre

$p(A)=0.750$

$p(B)=0.125$

$p(C)=0.125$

Entropía ≈ 0.735 bits

Confianza = 0.750

Métodos basados en la consistencia de las respuestas

- Estos métodos no evalúan una respuesta generada sino que integran la generación con el cálculo de incertidumbre
- **Ventajas:**
 - Puede funcionar mejor que los métodos anteriores
- **Desventajas:**
 - El costo escala con N , la cantidad de respuestas generadas

Cuatro familias de métodos



Verbalización

Se pide al modelo que declare su propia confianza en palabras o números



Probabilidades

Valor derivado de las probabilidades de token calculadas por el modelo



Consistencia

Se muestrea varias veces y se mide cuánto coinciden las respuestas




Probing

Modelos entrenados, basados en las activaciones del modelo

Métodos basados en probing

- Se entrena un modelo para predecir si la respuesta es correcta o incorrecta
- Las features de entrada son estados internos del LLM
- El entrenamiento se hace con datos anotados con etiqueta de correctitud



Métodos basados en probing

- **Ventajas:**

- Genera muy buenas probabilidades para prompts similares a los de entrenamiento
- Barato de correr

- **Desventajas:**

- Requiere acceso de caja blanca a las activaciones del modelo
- Requiere datos etiquetados para entrenamiento

Cuatro familias de métodos



Verbalización

Se pide al modelo que declare su propia confianza en palabras o números



Probabilidades

Valor derivado de las probabilidades de token calculadas por el modelo



Consistencia

Se muestrea varias veces y se mide cuánto coinciden las respuestas



Probing

Modelos entrenados, basados en las activaciones del modelo




PARTE II

Métodos para evaluar sistemas que producen respuestas + incertidumbre

Cuál es el sistema a evaluar?

- El sistema a evaluar tiene dos salidas:
 - La respuesta “candidata”
 - La medida de incertidumbre



- Cómo las va a usar el usuario final?
 - Va a aceptar o rechazar la respuesta comparando la incertidumbre con un umbral

Métricas estándar



- Se evalúan ambas salidas por separado
 - Datos para la evaluación: respuesta (a), incertidumbre (u), etiqueta (y)
- Para la **respuesta**, a :
 - Accuracy: porcentaje de respuestas que fueron correctas
 - Error rate: 1 - accuracy
- Para la **incertidumbre**, u :
 - Se considera un nuevo problema de clasificación **binario**: detectar correctitud a partir de la incertidumbre

1, correcto
0, incorrecto

Respuesta	Etiqueta	Incertidumbre
a_1	y_1	u_1
a_2	y_2	u_2
...	...	...
a_N	y_N	u_N

Métricas estándar

- Para la **incertidumbre** se usan métricas típicas de clasificación binaria
 - **Area bajo la curva ROC (AUC)**: mide discriminación
 - **Expected calibration error (ECE)**: mide sólo calibración
 - **Brier score**: mide ambas cosas juntas
- Las salidas deben ser confianzas, $P(\text{correcto} | p, a)$



Cómo elegimos el mejor sistema?


- Tenemos 2 o más métricas, qué pasa si se contradicen?
- Hay que priorizar una sobre otra, pero con qué criterio?

Sistema	Accuracy	AUC
A	0.95	0.85
B	0.82	0.90
C	0.88	0.70

El problema surge de usar métricas genéricas en vez de diseñar la métrica para el problema de interés

Cuál es el sistema a evaluar?


- El sistema a evaluar tiene dos salidas:
 - La respuesta “candidata”
 - La medida de incertidumbre



- Cómo las va a usar el usuario final?
 - Va a aceptar o rechazar la respuesta comparando la incertidumbre con un umbral

Cuál es el sistema a evaluar?

- Lo que hay que penalizar es:
 - Respuestas incorrectas aceptadas
 - El rechazo



Costo de Chow

- Una sola métrica que refleja el costo total del sistema, desde el punto de vista del usuario
 - Refleja el valor práctico del sistema
- Propuesto por Chow en 1957
 - Se usa muy poco en la actualidad

$$C(d) = \begin{cases} 0 & \text{si } d = a \text{ y } a \text{ es correcto} \\ \alpha & \text{si } d = r \\ 1 & \text{si } d = a \text{ y } a \text{ es incorrecto} \end{cases}$$

$\alpha < 1$, si no no se abstendría nunca

Promedio
sobre los
datos



$$\bar{C} = \text{Riesgo} + \alpha (1 - \text{Cobertura})$$




Porcentaje de error
sobre las muestras
aceptadas



Porcentaje de
muestras
aceptadas

Costo de Chow: toma de decisiones

- Cuándo acepto o rechazo?



- Teoría de decisión de Bayes: Tomo la **decisión que minimiza la esperanza del costo**
 - Para el costo de Chow, la decisión de Bayes es:

$$d = \begin{cases} a & \text{si } c > 1 - \alpha \\ r & \text{si } c < 1 - \alpha \end{cases}$$

Con $c = P(a \text{ es correcta} \mid p)$, la confianza


Costo de Chow: toma de decisiones

- El umbral de Bayes es óptimo sólo si las confianzas están bien calibradas
- Si no lo están, se puede tunear el umbral con datos de desarrollo

Curva de cobertura vs riesgo


- El valor de α depende de la aplicación
- Qué pasa si no sabemos cuál va a ser la aplicación?
- Una solución es no comprometerse a ningún valor!
 - Se varía el umbral de decisión y se registra la cobertura y el riesgo
 - Se obtiene la curva risk vs coverage - RC
 - Se mide el área bajo esa curva - AURC
- El AURC no mide si la confianza es una buena probabilidad, sólo si es discriminativa

$$\bar{C} = \text{Riesgo} + \alpha (1 - \text{Cobertura})$$




Integral del costo sobre α , ECUAS

- Otra opción, más elegante es integrar el costo de Chow sobre distintos valores de α
 - Para cada α se usa el umbral de Bayes
 - Se puede pesar el costo para cada α para darle más o menos importancia en la integral



Métricas - Resumen

- Usar métricas separadas para cada salida es mala idea
 - Sólo miden un aspecto del sistema
 - No se pueden comparar entre sistemas con distintas predicciones
- Eso nos deja con tres posibles familias de métricas: Costo de Chow, AURC, ECUAS



Etiquetas de correctitud

- En algunos casos son fáciles de asignar

- Clasificación
- Multiple choice

} Se compara la respuesta con el ground truth
(siempre que el prompt esté bien hecho y el LLM haga caso)

- En general no lo son

- Question-answering
- Resumen de textos
- Escritura creativa
- Codeo

} Hay un ground truth, pero la respuesta puede ser una paráfrasis

} No hay un ground truth

Pregunta: What does the term 'Halal' literally mean?

Ground Truth: permissible

Predicted: "Permitted" or "lawful"

Etiquetas de correctitud

- Cuando el etiquetado no es trivial, qué hacemos?
 - Ponemos a humanos a etiquetar
 - Ponemos a un LLM a etiquetar (LLM as a judge)

Pregunta: What does the term 'Halal' literally mean? As in Halal meat eaten by Muslims.

Ground Truth: permissible

Predicted: "Permitted" or "lawful"



Ambas pueden fallar, enturbiando los resultados de las evaluaciones

Etiquetas de correctitud

- Distintos sabores de “correctitud”
 - Fáctica: ¿la afirmación es verdadera?
 - *Cuál es la capital de Paris*
 - Cumplimiento de las instrucciones: ¿la respuesta respeta lo que se pidió en el prompt?
 - *Escribime un poema de 3 estrofas*
 - Honestidad: ¿la respuesta refleja la creencia del modelo?
 - *Es verdad que Adorni es corrupto?*
 - Estilo: ¿la respuesta tiene tono, formato, registro correctos?
 - *Necesito una respuesta para el revisor ...*
- Los métodos están generalmente dirigidos a correctitud fáctica

Resultados en TriviaQA

Method	Error rate	ECE	AUC	Brier Score	AURC	ECUAS
Prob. Secuencia	0.064	0.066	0.855	0.057	0.015	0.213
Verbalización - A posteriori	0.064	0.053	0.813	0.053	0.031	0.449
Verbalización - Integrada	0.059	0.049	0.743	0.054	0.016	0.503
	Calidad de las predicciones	Calidad de las confianzas		Calidad del sistema completo		

- El sistema que es mejor en ER y ECE no es el mejor para la tarea – sus confianzas tienen poca discriminación

Discusión final

- No hay consenso claro en la literatura sobre qué método es mejor cuándo
- Para caja blanca, probing parece ser lo mejor, mientras haya datos del dominio para entrenar
- Para caja negra, métodos basados en consistencia suelen ser mejores que las alternativas
- La elección de la métrica es esencial – debe corresponderse con la manera en que va a ser usado el sistema

Gracias!
Preguntas?

